

《机器学习导论》作业二

深入理解最大似然估计中的本质

聂嘉一 niejy20@lzu.edu.cn 220240945241

Lanzhou University

日期：2024 年 12 月 15 日

1 摘要

最大似然估计（Maximum Likelihood Estimation, MLE）作为参数估计的核心原则，可以推导出许多常见的损失函数。本次报告将从理论基础、本质分析、算法应用三个角度深入理解最大似然估计。第 2 节介绍最大似然估计的统计学定义，并给出伪代码算法；第 3 节从最大似然估计的视角理解最小二乘估计等常见模型；第 4 节介绍最大似然估计在算法中的应用。

2 最大似然估计的理论基础

2.1 定义

要深入理解最大似然估计，首先要对“似然”（Likelihood）有清晰的概念。

作为统计学中的另一个概念，“概率”（Probability）在生活中更常见：当我们知道参数 θ 时， $P(X = x|\theta)$ 表示事件 $X = x$ 发生的概率。简单来说，概率是在结果产生前，预测事件发生的概率。而似然与概率相反，它基于已有的数据来推测某些参数，即：当我们观察到了数据 x 时， $L(\theta|x)$ 表示参数 θ 产生这些数据的可能性。

最大似然估计就是选择能使似然函数 $L(\theta|x)$ 达到最大的参数值 θ 作为参数的估计值。例如，抛掷一枚硬币 10 次，观测到有 7 次为正面朝上，假设正面朝上的概率为 θ ，则分析似然函数 $L(\theta|x) = \theta^7(1 - \theta)^3$ 容易得到 θ 为 0.7 时，似然函数取最大值。

2.2 推导

假设有一组训练样本 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，则根据最大似然估计的原则，能找到使这些样本出现概率最大的参数 w 。由于样本是独立同分布的，联合概率就是各个样本条件概率的乘积。

由于概率的取值总是小于等于 1，多个概率相乘可能会遇到数值下溢的问题。为了简化计算并避免这个问题，我们通常使用对数似然函数，即将似然函数取自然对数：

$$\ell(\theta|D) = \log L(\theta|D) = \sum_{i=1}^n \log f(x_i; \theta)$$

由于对数函数本身是单调递增的，因此最大化似然函数等价于最大化对数似然函数。此外，对数将乘法转换为加法，从而避免了连乘导致的数值过小的问题。

假设我们有一个参数化的概率分布 $f(x; \theta)$ ，其中 θ 是未知参数，我们要基于给定的数据集来估计这个参数，使用极大似然估计的过程如算法1所示。

Algorithm 1: 最大似然估计

Input: 训练数据集 $\{x_1, x_2, \dots, x_n\}$ ，其中 $x_i \in \mathbb{R}^d$ ；概率模型 $f(x; \theta)$ ，其中 $\theta \in \Theta$ 是未知参数向量

Output: 最大似然估计参数 $\hat{\theta}$

初始化参数 θ 的初始值为 $\theta^{(0)}$ ；

repeat

$\ell(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$ ；

$\nabla_{\theta} \ell(\theta) = \left[\frac{\partial}{\partial \theta_j} \ell(\theta) \right]_{j=1}^{|\Theta|}$ ；

使用梯度上升或数值优化方法更新 θ ；

$\theta^{(t+1)} = \arg \max_{\theta} \ell(\theta)$ 或者使用迭代公式如 $\theta^{(t+1)} = \theta^{(t)} + \eta \nabla_{\theta} \ell(\theta^{(t)})$ ；

如果 $\|\theta^{(t+1)} - \theta^{(t)}\| < \epsilon$ 或者 $\|\nabla_{\theta} \ell(\theta^{(t+1)})\| < \epsilon$ 则停止；

until 收敛；

return $\hat{\theta} = \theta^{(t+1)}$ ；

3 最大似然估计的本质

最大似然估计在最小二乘估计、逻辑回归、softmax 回归等机器学习领域常见的模型中都有应用。

- 对于高斯分布，执行最大似然估计的结果就是最小二乘估计；
- 对于伯努利分布，执行最大似然估计的结果就是逻辑回归；
- 对于多项分布，执行最大似然估计的结果就是 softmax 回归。

3.1 最小二乘估计

假设有一个线性回归模型 $y = w^T x + \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 是独立同分布的高斯噪声。给定一组观测数据 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，可以写出每个观测值 y_i 的条件概率分布为：

$$P(y_i|x_i; w) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$

因为样本是独立同分布的，可以得到联合概率：

$$L(w|D) = \prod_{i=1}^n P(y_i|x_i; w) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$

如前文所述，为简化计算取对数似然函数：

$$\ell(w|D) = \sum_{i=1}^n \log P(y_i|x_i; w) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2$$

最大化对数似然函数等价于最小化最后一项，即负的均方误差（MSE）：

$$\text{MSE} = \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - w^T x_i)^2$$

因此，在高斯噪声假设下，进行最大似然估计等价于最小化均方误差，也就是最小二乘估计。

3.2 逻辑回归

在二元分类问题中，常使用逻辑回归模型来预测一个样本属于正类的概率。设 $p = P(y = 1|x; \theta)$ 是给定 x 条件下样本属于正类的概率，则逻辑回归模型的形式为：

$$p = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

这里 $\sigma(z)$ 是 sigmoid 函数。对于伯努利分布 $y \in \{0, 1\}$ ，给定 x 和参数 θ 的条件下， y 的概率可以表示为：

$$P(y|x; \theta) = p^y (1 - p)^{1-y}$$

对于一组训练样本 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，对数似然函数为：

$$\ell(\theta|D) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

这里 $p_i = \sigma(\theta^T x_i)$ 。最大化对数似然等价于求它的负值的最小值，这就是交叉熵损失函数（Binary Cross-Entropy Loss）：

$$\text{BCE} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

因此，在伯努利分布假设下，进行最大似然估计等价于最小化交叉熵损失，也就是逻辑回归。

3.3 Softmax 回归

在多分类问题中，我们使用 softmax 回归模型来预测一个样本属于各个类别的概率。设 $p_j = P(y = j|x; \Theta)$ 是给定 x 条件下样本属于类别 j 的概率，则 softmax 回归模型的形式为：

$$p_j = \frac{\exp(\theta_j^T x)}{\sum_{k=1}^K \exp(\theta_k^T x)}$$

这里 $\Theta = [\theta_1, \theta_2, \dots, \theta_K]$ 是模型参数矩阵， K 是类别数量。对于多项分布 $y \in \{1, 2, \dots, K\}$ ，给定 x 和参数 Θ 的条件下， y 的概率可以表示为：

$$P(y = j|x; \Theta) = p_j$$

对于一组训练样本 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，对数似然函数为：

$$\ell(\Theta|D) = \sum_{i=1}^n \log P(y_i|x_i; \Theta) = \sum_{i=1}^n \log p_{y_i}$$

这里 p_{y_i} 表示第 i 个样本真实类别 y_i 的概率。如前文所述，求对数似然函数的最大值等价于求它的负值的最小值，即多分类交叉熵损失函数（Categorical Cross-Entropy Loss）：

$$\text{CCE} = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^K 1\{y_i = j\} \log p_j$$

因此，在多项分布假设下，进行最大似然估计等价于最小化多分类交叉熵损失，也就是 softmax 回归。

4 最大似然估计在人工智能算法中的应用

除第 3 节提到的三种模型之外，最大似然估计还在下文所述的模型中有应用。

4.1 朴素贝叶斯分类器

朴素贝叶斯分类器利用贝叶斯定理结合特征条件独立的假设来进行分类。MLE 在该模型中可用于从训练数据中估计类先验概率和条件概率。

4.2 隐马尔可夫模型

隐马尔可夫模型常用于时间序列分析，广泛应用于语音识别等领域。MLE 在该模型中可用于估计模型的转移概率和发射概率。

4.3 自然语言处理

在自然语言处理中，MLE 可用于解决词频统计、序列标注等问题。例如，在训练 n-gram 语言模型时，MLE 用于估计词语序列出现的概率。

5 结论

最小二乘估计、逻辑回归和 softmax 回归都可以看作是在特定概率分布假设下的最大似然估计。它们分别对应于高斯分布、伯努利分布和多项分布。

通过查阅资料^[1-5]与推导原理，我认识到最大似然估计提供了一种系统化的方法来从数据中推断模型的未知参数，无论是经典的统计模型还是现代的机器学习算法，MLE 都是一个不可或缺的重要工具。

6 致谢

本文 L^AT_EX 模板为ElegantPaper。

本文部分知识来自机器学习导论。

参考文献

- [1] Ramya Korlakai Vinayak et al. “Maximum likelihood estimation for learning populations of parameters”. In: *International Conference on Machine Learning*. PMLR. 2019, pp. 6448–6457.
- [2] Mark J van der Laan and Sherri Rose. “Why machine learning cannot ignore maximum likelihood estimation”. In: *Handbook of Matching and Weighting Adjustments for Causal Inference*. Chapman and Hall/CRC, 2023, pp. 483–500.
- [3] I Nitze, U Schulthess, and H Asche. “Comparison of machine learning algorithms random forest, artificial neural network and support vector machine to maximum likelihood for supervised crop type classification”. In: *Proceedings of the 4th GEOBIA, Rio de Janeiro, Brazil 79* (2012), p. 3540.
- [4] In Jae Myung. “Tutorial on maximum likelihood estimation”. In: *Journal of mathematical Psychology* 47.1 (2003), pp. 90–100.
- [5] Christopher M Bishop and Nasser M Nasrabadi. *Pattern recognition and machine learning*. Vol. 4. 4. Springer, 2006.